



## Proyecto Final

**¿Es posible predecir si un estudiante de enseñanza media (3°/ 4° medio) en Chile abandonará el sistema escolar antes de completar su educación utilizando algoritmos de machine learning?**

Diana Adco  
[diana.adco97@uc.cl](mailto:diana.adco97@uc.cl)

Xiomara Kuwae  
[xmkuwae@uc.cl](mailto:xmkuwae@uc.cl)

Luis José López  
[luis.laureano@uc.cl](mailto:luis.laureano@uc.cl)

### Resumen

Este estudio busca predecir el riesgo de deserción escolar en estudiantes de 3° y 4° medio en Chile, utilizando modelos de machine learning. Para ello, se construyó un panel con datos administrativos del Ministerio de Educación entre los años 2017 y 2024, integrando información de rendimiento académico, asistencia y variables socioeducativas. Se aplicaron técnicas de feature engineering, manejo de clases desbalanceadas y selección de características relevantes. Los modelos entrenados –XGBoost y Multilayer Perceptron– fueron evaluados utilizando diversas métricas. Los resultados muestran que, si bien ambos modelos presentan similar desempeño, el Multilayer Perceptron destaca por su mayor capacidad de identificar estudiantes en riesgo de deserción, alcanzando un recall de 74 %. Esto evidencia el potencial del machine learning como herramienta de alerta temprana para la intervención educativa focalizada.

## I. Introducción

La deserción escolar en la educación media constituye uno de los desafíos más críticos del sistema educativo chileno, representando no solo una pérdida individual de oportunidades, sino también un costo social y económico significativo para el país. Como señalan Espinoza et al. (2014), la deserción escolar se vincula directamente con el círculo de exclusión y pobreza, impactando las trayectorias futuras de adolescentes y jóvenes de sectores vulnerables. La identificación temprana de estudiantes en riesgo de abandonar sus estudios es fundamental para implementar intervenciones preventivas efectivas y optimizar la asignación de recursos limitados en políticas públicas educacionales.

El presente trabajo aborda la predicción de deserción escolar en estudiantes de 3° y 4° medio mediante técnicas de machine learning, utilizando datos administrativos del Ministerio de Educación de Chile del 2017-2024 <sup>1</sup> (MINEDUC, 2025). Esta investigación es particularmente relevante considerando el contexto de interrupciones educativas recientes, incluyendo el estallido social de 2019 y la pandemia de COVID-19.

La literatura científica ha identificado múltiples factores asociados a la deserción escolar. Investigaciones fundacionales establecieron que los factores predictores no solo se relacionan con el comportamien-

---

<sup>1</sup>Deserción = abandono definitivo al final del año escolar, excluyendo reincorporaciones.

to estudiantil, sino también con características institucionales (Rumberger, 1987; Battin-Pearson et al., 2000). Estudios más recientes han confirmado la relevancia de variables socioeconómicas y expectativas familiares (Espinoza et al., 2014; Espinoza et al., 2020; Foley et al., 2014), mientras que investigaciones contemporáneas han incorporado técnicas de machine learning para mejorar significativamente la capacidad predictiva (Krüger et al., 2023; Nagy y Molontay, 2024).

Este trabajo contribuye mediante: (1) la aplicación de algoritmos con diferentes estrategias de balanceo de clases, usando `scale_pos_weight` en XGBoost y SMOTE en MLP (Villarreal-Torres et al., 2023); (2) la incorporación de variables contextuales como efectos de pandemia y crisis social; (3) la implementación de feature engineering avanzado, incluyendo target encoding geográfico <sup>2</sup>; y (4) el uso de recall como métrica principal de evaluación, priorizando la identificación completa de estudiantes en riesgo dado que el costo de intervenciones informativas de alerta temprana es significativamente menor que el costo de no detectar desertores reales, complementado con precision y F1-score para un análisis integral del modelo.

La pregunta de investigación central es: ¿En qué medida pueden los algoritmos XGBoost y MLP predecir con precisión la deserción escolar en estudiantes de educación media (3º/ 4º medio), y cuáles son los factores más determinantes? Los hallazgos tienen implicaciones directas para el diseño de sistemas de alerta temprana y la focalización de intervenciones preventivas en el sistema educativo chileno.

## II. Metodología

Para la predicción de la deserción escolar, se construyó una base de datos longitudinal con múltiples cohortes escolares y se entrenaron dos modelos: **XGBoost** y **Multilayer Perceptron**.

### 2.1. Fuentes de datos y filtrado

En la etapa de construcción del set de datos, se integraron registros anuales provenientes del Ministerio de Educación (s.f.). Para ello, se descargaron y procesaron las siguientes bases de datos:

- **Rendimiento académico por estudiante** para los años 2016 a 2024, los cuales contienen información sobre notas, asistencia y características del estudiante y establecimiento. Se incluyó el 2016 para generar variables históricas.
- **Alumnos preferentes, prioritarios y beneficiarios SEP** para los años 2017 a 2024. Éstas contienen antecedentes de subvenciones y vulnerabilidad del Programa de Subvención Escolar Preferencial (SEP).

Luego, se filtraron las bases de rendimiento para incluir únicamente a estudiantes de segundo, tercero y cuarto medio. El grupo objetivo son los terceros y cuartos medios, mientras que los de segundo se consideraron para generar variables históricas (promedio de notas y asistencia del año anterior) sin incurrir en *data leakage*. Esto se debe a que utilizar variables del mismo año, como `PROM_GRAL` podría entregar información posterior a la predicción, ya que los desertores registran promedio cero. Asimismo, las bases SEP se filtraron para conservar a los alumnos de tercero y cuarto medio.

### 2.2. Pre-procesamiento

#### 2.2.1. Concatenación y merge

Previo a integrar las bases de datos, se eliminó a los alumnos duplicados (con `MRUN` repetido), reteniendo sólo a los estudiantes que aparecían una vez en cada base para evitar errores en el *merge*.

Luego, se consolidó la base de **rendimiento escolar**, concatenando los dataframes de cada año, y se crearon las variables `PROM_GRAL_ANTERIOR` y `ASISTENCIA_ANTERIOR`, a partir del dato de `PROM_GRAL` y `ASISTENCIA` del período  $t - 1$ . Finalmente, se eliminaron las observaciones de 2016 y segundo medio.

De manera similar, se consolidó la base de datos del **programa SEP**. Esto permite unir las bases de rendimiento escolar y programa SEP, mediante el identificador de los alumnos (`MRUN`) y año (`AGNO`).

---

<sup>2</sup>Reemplaza variables territoriales por la tasa de deserción promedio de cada región/comuna.

### 2.2.2. Definición de variables

Se construyó la variable target `DESERTAR`, variable binaria, que indica si el estudiante fue clasificado como desertor ("Retirado") según la variable `SIT.FIN_R` en la base de datos. Además, se decidió:

- Excluir establecimientos particulares pagados, debido a que no están obligados a reportar asistencia.
- Eliminar registros con valores faltantes en la variable target y eliminar atributos que no se utilizarán.

## 2.3. Análisis Exploratorio de Datos

El análisis exploratorio se enfocó en entender la distribución y calidad de los datos, detectar valores atípicos (*outliers*) y evaluar la relación entre variables predictoras y la deserción escolar. Esto permitirá tomar decisiones de depuración y creación de variables en la etapa de *feature engineering*.

Se analizaron **variables numéricas** a través de histogramas, binscatters y un mapa de correlación, encontrándose una correlación positiva entre rendimiento y asistencia, y una concentración de desertores entre quienes presentan promedio cero o baja asistencia.

Asimismo, se revisaron **variables categóricas** como género, condición de alumno prioritario o beneficiario SEP, ruralidad y dependencia del establecimiento. Se observó mayor proporción de deserción en hombres, estudiantes rurales y de establecimientos de dependencia municipal.

## 2.4. Feature Engineering

En esta etapa se diseñaron y transformaron variables para mejorar el rendimiento de los modelos.

Primero, se eliminaron registros con datos faltantes en `PROM.GRAL_ANTERIOR`, `ASISTENCIA_ANTERIOR` y `EDAD_ALU`. Se optó por eliminar y no imputar, para mantener la calidad del dataset y no añadir sesgo. También se eliminaron registros con edades atípicas y género indeterminado.

Dentro de las transformaciones relevantes y creación de variables se encuentran:

- Creación de *dummies* de coincidencia entre comuna del establecimiento y de residencia (`MISMA_COMUNA`), para shocks por pandemia (2020-2021), estallido social (2019) y género (`MUJER`).
- Reclasificación de escuelas dependientes de SLEP en la categoría municipal para controlar la dimensionalidad. Luego, se aplicó *one-hot encoding* a la variable `COD_DEPE2`, creándose *dummies* por categoría.
- *Target encoding* con suavizado para la comuna del establecimiento (`COD_TARGET_SMOOTH`), permitiendo añadir información de riesgo por comuna, evitando el sobreajuste en zonas con pocos datos.
- *Bucketización* por tipo de enseñanza (`COD_ENSE`), mapeándolos entre dos categorías: científico humanista y técnico profesional, para luego aplicar *one-hot encoding*.
- Aplicación de *one-hot encoding* a la variable `COD_GRADO`.

Por último, con el objetivo de reducir la **dimensionalidad** del conjunto de datos y evitar problemas de multicolinealidad, se eliminaron ciertas variables redundantes o derivadas de codificaciones mutuamente excluyentes. En particular, se excluyó `GRADO_4`, ya que se contaba con variables indicadoras tanto para tercero como cuarto medio, siendo suficiente conservar sólo una de ellas. De manera análoga, se descartó `ENSE.Científico Humanista`, manteniéndose la variable complementaria `ENSE.Técnico Profesional`. Asimismo, se eliminó `PREFERENTE_ALU`, debido a que presentaba una correlación perfectamente negativa con `PRIORITARIO_ALU`, representando categorías mutuamente excluyentes codificadas como *dummies*. También, se descartaron los códigos de comuna de residencia y de establecimiento, `COD_COM_ALU` y `COD_COM_RBD`, ya que se cuenta con información geográfica con la variable `COD_TARGET_SMOOTH`. Finalmente, se eliminó el identificador del alumno (`MRUN`), porque no contiene información predictiva útil, y también `AGNO`, ya que se cuenta con *dummies* para los períodos de shocks relevantes.

## 2.5. Entrenamiento

Una vez finalizado el proceso de limpieza, transformación y enriquecimiento del conjunto de datos, se procedió a la fase de entrenamiento de modelos con 1,171,771 observaciones y 17 features.

Para evaluar adecuadamente el desempeño de los modelos, se dividió la muestra en conjuntos de entrenamiento (*train*) y testeo (*test*), utilizando una partición estratificada para preservar la proporción de estudiantes desertores en ambas muestras. Dado que la clase positiva es minoritaria, esta división es crucial para obtener resultados robustos. Luego, se entrenaron los siguientes modelos:

- **XGBoost:** Se entrenó un modelo de *gradient boosting* utilizando la librería `xgboost`. Dado el fuerte desbalance de clases, se ajustó el hiperparámetro `scale_pos_weight` como el cociente entre observaciones negativas y positivas. Para la selección de hiperparámetros se utilizó `RandomizedSearchCV`, donde se definió un *scorer* personalizado basado en `average_precision_score`, correspondiente al área bajo la curva *precision-recall* (AUC-PR), útil en contextos altamente desbalanceados, pues evalúa la calidad de las predicciones positivas. La búsqueda aleatoria se realizó con validación cruzada, y se exploraron combinaciones de hiperparámetros como profundidad máxima del árbol, tasa de aprendizaje, peso mínimo de hijos (mínimo número de observaciones en una hoja), ganancia mínima para dividir, proporción de muestras y variables por árbol y número de árboles (estimadores). Adicionalmente, se realizó el ejercicio de ajustar el umbral de decisión para maximizar el **F1 Score**, buscando un equilibrio entre *precision* y *recall*, y así analizar el *trade-off* entre estas métricas y cómo difieren los resultados.
- **Multilayer Perceptron (MLP):** También se entrenó un clasificador basado en redes neuronales utilizando la clase `MLPClassifier` de `scikit-learn`, con las variables numéricas reales normalizadas. Este modelo permite capturar relaciones no lineales entre las variables mediante una arquitectura multicapa con propagación hacia adelante. Se exploraron diferentes combinaciones ajustando hiperparámetros como el número y tamaño de capas ocultas, funciones de activación (`relu`, `tanh`), tasa de aprendizaje inicial, penalización L2 (`alpha`) y el optimizador (`adam`). Para prevenir sobreajuste, se utilizó `early_stopping`, lo que interrumpe el entrenamiento si no se observan mejoras en la validación.

## III. Resultados

En esta sección evaluaremos el desempeño de los modelos utilizados: XGBoost y Multilayer Perceptron, cada uno por separado y compararemos la efectividad de ambos.

### 3.1. XGBoost

Primero se evaluará el modelo XGBoost detallado en la sección anterior. Como podemos ver en el gráfico 1 el modelo tomó un tiempo de 34 minutos y 51 segundos, con un accuracy en el set de testeo de 88,2 % y un recall de 61,8 %. Para llegar a este resultado, se probaron más de 25 combinaciones de hiperparámetros, desde cantidad de estimaciones, profundidad máxima de árboles, tasa de aprendizaje, peso para balancear el test de entrenamiento, entre otras y dividiendo la muestra 5 veces de manera aleatoria, resultando en 125 iteraciones distintas. Con estas pruebas se llegó a una submuestra más pequeña de 70 % –para compensar el tiempo de cómputo alto– un peso de 98.31 para observaciones desbalanceadas, 200 estimaciones, una profundidad máxima de 10 ramas en cada árbol y tasa de aprendizaje de 10 %.

Sin embargo, el modelo no logra identificar correctamente los casos donde los estudiantes desertan y provoca una alta cantidad de casos calificados erróneamente como desertor cuando realmente no lo son en aproximadamente 12 % de todas las observaciones –ver Anexo 2. Por este mismo motivo, el modelo presenta un F1 score bajo, por alto recall pero muy baja precisión– precisión de 16,6 %, provocando un F1 score de 9,5 %. Aún probando una estimación alternativa, realizando cambios en el threshold utilizado, buscando maximizar el F1 score este no incrementa considerablemente. Con un threshold de 0.88 –ver gráfico 3–, vemos que se maximiza el F1 score, incrementando la precisión del modelo hasta 16,6 %, pero con el costo asociado de la caída en el recall hasta 21,6 %, resultando en un F1 score de 19,6 %. Este bajo

recall puede provocar un exceso de alertas de detección temprana de posibles desertores. Las implicancias de estos resultados se detallarán en la próxima sección.

### 3.2. Multilayer Perceptron

Para el multilayer perceptron, se realizó una estimación con funciones de activación lineales, una tasa de aprendizaje adaptativa y solver con el método Adam. Debido al tiempo de cómputo, se optó por reducir las particiones de la base de entrenamiento y la cantidad de hiperpárametros a probar. Con esto, se dividió la base de entrenamiento 3 veces de manera aleatoria, con 3 combinaciones de hiperpárametros: cantidad de neuronas en capas ocultas y un alpha de penalización del modelo. Con esto, los resultados del modelo arrojaron que la mejor combinación es de 30 neuronas en capas ocultas y alpha de 0.001, arrojando un rendimiento comparable al de XGBoost con 80,7 %, con una precisión de 3,75 % y recall de 74,01 % para un F1 score de 7,14 %.

El modelo MLP, a pesar de tener un accuracy y recall mayor que el XGBoost, sufre del mismo problema de levantar una alta cantidad de casos falsos positivos –ver Anexo 7– alrededor de 19 % de las observaciones. El resultado es similar al encontrado en XGBoost, a pesar de que en este modelo de MLP se optó por balancear la muestra con SMOTE, buscando una mejor precisión –que aunque lograda– no supera considerablemente el XGBoost, siendo similar a la hora de sobrestimar la cantidad de desertores, arrojando un exceso de alertas.

## IV. Discusión

### 4.1. Análisis comparativo de Performance

Los resultados obtenidos revelan diferencias significativas en el desempeño de ambos modelos para la predicción de deserción escolar en educación media chilena. Como se observa en la tabla comparativa, XGBoost demostró superioridad general en la mayoría de métricas evaluadas.

Tabla 1: Comparación de Performance entre Modelos

Métrica	XGBoost	MLP	Diferencia	Mejor Modelo
Precision	0.0515	0.0375	+0.0140	XGBoost
Recall	0.6175	0.7401	-0.1226	MLP
F1-Score	0.0951	0.0714	+0.0237	XGBoost
ROC-AUC	0.8457	0.8400	+0.0057	XGBoost
Accuracy Test	0.8819	0.8066	+0.0753	XGBoost
Tiempo (seg)	2,092	1,513	+579	MLP

XGBoost alcanzó accuracy superior (88,19 % vs 80,66 %) y mejor F1-score (0,0951 vs 0,0714), mientras MLP mostró mayor sensibilidad para detectar desertores (recall: 74,01 % vs 61,75 %) aunque con menor precision (3,75 % vs 5,15 %). Ambos modelos presentaron capacidad discriminativa similar (AUC-ROC), sugiriendo diferencias en calibración de probabilidades. Dado la contribución (4) mencionada en la introducción, priorizamos recall como métrica principal, MLP valida la estrategia metodológica al lograr superior detección con menor costo computacional, cumpliendo el objetivo de maximizar sensibilidad sobre precision en política educativa preventiva.

#### Potenciales causas de las diferencias:

- **Tratamiento del desbalanceo:** XGBoost utilizó *scale\_pos\_weight* = 98,31 optimizando balance general entre métricas, mientras MLP con SMOTE generó datos sintéticos de desertores que incrementaron su sensibilidad, explicando el superior recall (74,01 % vs 61,75 %).
- **Arquitectura:** XGBoost demostró robustez en múltiples métricas simultáneamente, mientras MLP se especializó en maximizar detección de la clase minoritaria.

- **Robustez** XGBoost maneja variables heterogéneas sin preprocesamiento extensivo, favoreciendo estabilidad, mientras MLP requirió escalado y datos sintéticos que, aunque agregan complejidad, resultan en mayor capacidad de detección.

## 4.2. Uso de técnicas de Explicabilidad

Los análisis de explicabilidad revelaron divergencias fundamentales entre modelos.

- XGBoost priorizó factores contextuales: Feature Importance identificó COMUNA\_TARGET\_SMOOTH (11,370 puntos), ASISTENCIA\_ANTERIOR (8,841) y PROM\_GRAL\_ANTERIOR (7,752) como dominantes ([Anexo 6](#)), con SHAP confirmando que valores bajos incrementan la probabilidad de deserción ([Anexo 7](#)).
- MLP enfatizó estructura institucional: Permutation Importance priorizó dependencias educacionales (DEPE\_1, DEPE\_2) sobre factores territoriales ([Anexo 8](#)), sugiriendo que el entrenamiento con SMOTE desarrolló sensibilidad hacia patrones institucionales ([Anexo 9](#)).

**Implicaciones:** Esta divergencia indica que ambos modelos operan con lógicas predictivas distintas XGBoost captura determinantes socioeconómicos, mientras MLP se focaliza en características sistémicas limitando la robustez de conclusiones generalizables.

## 4.3. Implicaciones para Política Pública

Los hallazgos respaldan la implementación de MLP como sistema de alerta temprana a nivel nacional. Si bien XGBoost presenta accuracy superior (88,19 % vs 80,66 %), para este trabajo priorizamos *recall* como métrica principal dado que en política educativa es preferible detectar todos los casos en riesgo aunque se generen intervenciones innecesarias (costo-beneficio). MLP demuestra superior capacidad de detección (*recall*: 74,01 %) y eficiencia computacional (1,513 vs 2,092 segundos), procesando 878,829 estudiantes en entrenamiento y 292,943 en test con 17 variables predictivas.

La estrategia óptima utiliza el ranking por probabilidad de MLP para seleccionar los  $N$  estudiantes con mayor riesgo según disponibilidad presupuestaria, priorizando cobertura máxima sobre *precision*. El énfasis institucional de MLP en dependencias educacionales (DEPE\_1, DEPE\_2), complementado con factores académicos (PROM\_GRAL\_ANTERIOR), sugiere intervenciones sistémicas diferenciadas por tipo de establecimiento.

La divergencia entre modelos sugiere implementar MLP como detector primario por su superior *recall*, complementado con análisis territorial de XGBoost para focalización geográfica, maximizando tanto detección individual como estrategias territorializadas de intervención preventiva.

## V. Conclusiones

La deserción escolar ha sido uno de los grandes retos en el sistema educativo chileno actual, planteando un riesgo para el desarrollo profesional futuro de los jóvenes. En el presente documento tratamos de probar si es posible predecir con antelación a los desertores escolares, buscando reducir el riesgo de que estos lo hagan. Nuestro modelo resultó ser bueno para predecir la mayor parte de los casos, pero dado el desbalance, tiende a sobrestimar los probables desertores.

Con nuestros resultados, podemos ver que variables como promedios generales bajos así como las características de la comuna donde se ubica la escuela, son factores clave para aproximar la probabilidad de deserción. Sin embargo, resulta vital tomar en consideración que con estos resultados, lo óptimo sería organizar los estudiantes por mayor probabilidad de desertar y focalizar los esfuerzos –ya sea contactando al estudiante y/o su familia, organizando jornadas de conscientización de la relevancia escolar o designar tutorías personalizadas– en estudiantes de peor calificación en las comunas más vulnerables.

## Referencias

- [1] Battin-Pearson, S., Newcomb, M. D., Abbott, R. D., Hill, K. G., Catalano, R. F., & Hawkins, J. D. (2000). Predictors of early high school dropout: A test of five theories. *Journal of Educational Psychology*, 92(3), 568–582. <https://doi.org/10.1037/0022-0663.92.3.568>
- [2] Espinoza, O., Castillo, D., González, L. E., Santa Cruz, E., & Loyola, J. (2014). Deserción escolar en Chile: un estudio de caso en relación a factores intraescolares. *Educación y Educadores*, 17(1), 32–50. <https://doi.org/10.5294/edu.2014.17.1.2>
- [3] Espinoza, O., González, L. E., McGinn, N., & Castillo, D. (2020). What factors predict the engagement of dropouts in alternative schools in Chile? *Improving Schools*, 23(1), 43–67. <https://doi.org/10.1177/1365480219864835>
- [4] Foley, K., Gallipoli, G., & Green, D. A. (2014). Ability, parental valuation of education, and the high school dropout decision. *Journal of Human Resources*, 49(4), 906–944. <https://doi.org/10.3368/jhr.49.4.906>
- [5] Kim, S., Choi, E., Jun, Y.-K., & Lee, S. (2023). Student dropout prediction for university with high precision and recall. *Applied Sciences*, 13(11), 6275. <https://doi.org/10.3390/app13116275>
- [6] Krüger, J. G., Britto Jr., A. S., & Barddal, J. P. (2023). An explainable machine learning approach for student dropout prediction. *Expert Systems with Applications*, 233, 120933. <https://doi.org/10.1016/j.eswa.2023.120933>
- [7] Ministerio de Educación de Chile. (s.f.) *Alumnos Preferentes, Prioritarios y Beneficiarios SEP*. Disponible en: <https://datosabiertos.mineduc.cl/alumnos-preferentes-prioritarios-y-beneficiarios-sep/> [Consulta: 20 de junio de 2025].
- [8] Ministerio de Educación de Chile. (2025). Datos Abiertos. *Centro de Estudios MINEDUC*. <https://datosabiertos.mineduc.cl/>
- [9] Ministerio de Educación de Chile. (s.f.) *Rendimiento por estudiante*. Disponible en: <https://datosabiertos.mineduc.cl/rendimiento-por-estudiante-2/> [Consulta: 20 de junio de 2025].
- [10] Nagy, M., & Molontay, R. (2024). Interpretable dropout prediction: Towards XAI-based personalized intervention. *International Journal of Artificial Intelligence in Education*, 34, 274–300. <https://doi.org/10.1007/s40593-023-00331-8>
- [11] Rumberger, R. W. (1987). High school dropouts: A review of issues and evidence. *Review of Educational Research*, 57(2), 101–121. <https://doi.org/10.3102/00346543057002101>
- [12] Villarreal-Torres, H., Ángeles-Morales, J., Marín-Rodríguez, W., Andrade-Girón, D., Carreño-Cisneros, E., Cano-Mejía, J., Mejía-Murillo, C., Boscán-Carroz, M. C., Flores-Reyes, G., & Cruz-Cruz, O. (2023). Development of a classification model for predicting student payment behavior using artificial intelligence and data science techniques. *EAI Endorsed Transactions on Scalable Information Systems*, 10(4), e15. <https://doi.org/10.4108/eetsis.v10i4.2895>

# Anexos

## Anexo 1

```
Accuracy entrenamiento: 0.8885
Accuracy testeo: 0.8819
Precision: 0.0515
Recall: 0.6175
F1 Score: 0.0951
AUC ROC: 0.8457
AUC PR: 0.1080
Tiempo de ejecución: 2091.62 segundos

>>> Umbral óptimo para F1: 0.88, F1: 0.1961
=== Métricas con umbral ajustado ===
Precision: 0.1657
Recall: 0.2401
F1 Score: 0.1961
```




Figura 1: Métricas de desempeño - XGBoost



## Anexo 2




Figura 2: Matriz de confusión - XGBoost

## Anexo 3

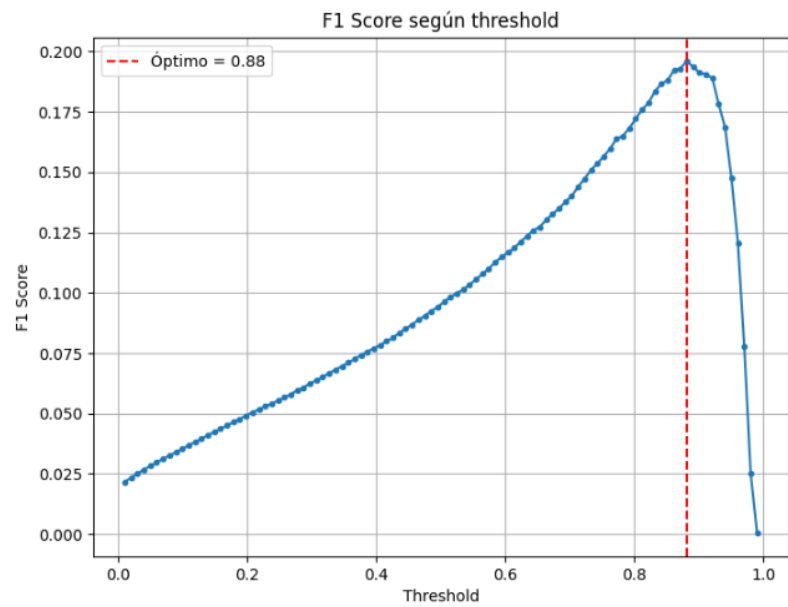


Figura 3: F1 score según threshold - XGBoost

## Anexo 4

MLP Performance:  
Accuracy Train: 0.8159  
Accuracy Test: 0.8066  
Precision: 0.0375  
Recall: 0.7401  
F1 Score: 0.0714  
AUC ROC: 0.8471  
AUC PR: 0.0963  
Tiempo de ejecución: 1513.40 segundos




Figura 4: Métricas de desempeño - MLP

## Anexo 5




Figura 5: Matriz de confusión - MLP

## Anexo 6

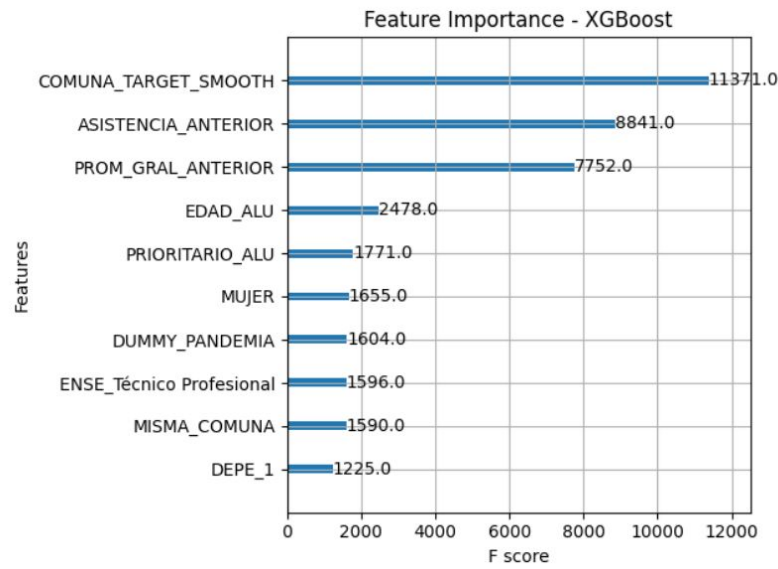


Figura 6: Importancia de variables - XGBoost

## Anexo 7




Figura 7: Factores de Riesgo y Protección en Deserción Escolar (SHAP)

## Anexo 8




Figura 8: Importancia de variables - MLP

## Anexo 9




Figura 9: Factores de Riesgo y Protección en Deserción Escolar (SHAP)